



计算机工程

Computer Engineering

ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：基于聚类的去中心化联邦遗忘方法
作者：肖志强，贾俊铖
DOI：10.19678/j.issn.1000-3428.0252244
网络首发日期：2025-07-23
引用格式：肖志强，贾俊铖. 基于聚类的去中心化联邦遗忘方法[J/OL]. 计算机工程.
<https://doi.org/10.19678/j.issn.1000-3428.0252244>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于聚类的去中心化联邦遗忘方法

肖志强, 贾俊铖*

(苏州大学, 计算机科学与技术学院, 江苏 苏州 215001)

摘 要: 数据隐私法规要求机器学习模型具备安全移除用户数据的能力, 以高效响应遗忘请求。然而, 在去中心化联邦学习(DFL)环境中, 遗忘学习面临多轮参数传播导致的重训练成本高昂问题, 同时客户端计算能力、通信带宽异构性及非独立同分布(Non-IID)特性显著阻碍模型收敛。现有研究多集中于中心化联邦学习场景, 对去中心化联邦遗忘机制的探索不足。为此, 本文提出了一种基于聚类的去中心化联邦遗忘方法(CDFU), 通过客户端聚类和高效率的拓扑学习提升遗忘效率。CDFU 采用本文设计的分层聚类算法(HCK), 根据计算能力、通信带宽和数据分布特征进行粗聚类与细粒度划分, 形成时间同步且数据分布均衡的集群, 将遗忘重训练限定于受影响集群, 从而降低计算和通信开销。划分完成后, CDFU 通过时延优化的拓扑学习算法(LOTL)构建并优化集群内通信拓扑, 减少通信延迟, 加速模型收敛。实验表明, CDFU 在多个数据集上显著提升训练效率, 测试准确率平均提高 10.2%, 优于现有方法。

关键词: 联邦学习; 去中心化联邦学习; 遗忘学习; 聚类; 拓扑学习。

DOI:10.19678/j.issn.1000-3428.0252244

Clustering-Based Decentralized Federated Unlearning Method

Zhiqiang Xiao, Juncheng Jia*

(School of Computer Science and Technology, Soochow University, Suzhou, 215001, Jiangsu, China)

【Abstract】 Data privacy regulations mandate that machine learning models possess the capability to securely remove user data, enabling efficient responses to unlearning requests. However, in the context of Decentralized Federated Learning (DFL), unlearning is challenged by the high retraining costs resulting from multi-round parameter propagation, alongside client heterogeneity in computational power, communication bandwidth, and non-independent and identically distributed (Non-IID) data characteristics, which significantly impede model convergence. Existing research predominantly focuses on centralized federated learning scenarios, with limited exploration of unlearning mechanisms in DFL. To address this, this paper proposes a clustering-based decentralized federated unlearning method (CDFU), enhancing unlearning efficiency through client clustering and optimized topology learning. CDFU employs the proposed Hierarchical Clustering algorithm (HCK), which performs coarse and fine-grained clustering based on computational power, communication bandwidth, and data distribution features, forming time-synchronized and data-balanced clusters. This confines retraining to affected clusters, thereby reducing computational and communication overheads. Following clustering, CDFU utilizes a latency-optimized Topology Learning algorithm (LOTL) to construct and refine the intra-cluster communication topology, minimizing communication delays and accelerating model convergence. Experimental results demonstrate that CDFU significantly improves training efficiency across multiple datasets, achieving an average increase of 10.2% in test accuracy compared to existing methods.

【Key words】 Federated Learning; Decentralized Federated Learning; Unlearning; Clustering; Topology Learning.

0 引言

随着物联网技术发展, 边缘设备处理能力不断增强。为高效利用其采集数据, 深度学习等技术在智慧物联网领域逐步推广。传统人工智能依赖集中式云端处理^[1], 但面临高通信成本和数据隐私风险的双重挑战。因此, 研究者提出分布式机器学习新范式——联邦学习(FL)^[2]。联邦学习通过本地化训练降低隐私泄露风险, 同时减轻计算负荷, 但其通信效率和模型一致性仍面临挑战^[3]。根据架构类型的不同, 联邦学习可分为集中式联邦学习(CFL)和去中心化联邦学习(DFL)^[4]。其中 DFL 通过客户

端间的点对点通信实现分布式训练, 有效分散通信负载并降低隐私泄露风险^[5]。但是 DFL 的完全去中心化特性显著增加了通信协调复杂度, 在确保模型一致性和收敛性方面面临严峻挑战。为缓解这些问题, 研究者在提高通信效率和隐私保护方面展开了大量探索。例如, 刘炜等人^[6]提出基于区块链和梯度压缩的模型, 利用智能合约和热身训练提升隐私与效率。周炜等人^[7]设计基于区块链的隐私保护模型, 结合同态加密和信誉机制确保安全与公平。

近年来, 数据隐私保护备受全球立法关注。欧盟《通用数据保护条例》(GDPR)^[8]、《加州消费者隐私

法案》(CCPA)^[9]、日本《数据保护概述》(JDPO)^[10] 以及加拿大拟议的《消费者隐私保护法》(CPPA)^[11]等法规相继确立“被遗忘权”，赋予用户删除个人数据的法定权利。所以，机器学习模型需要具备移除特定数据影响的能力。这推动了机器遗忘学习的发展，成为隐私保护的重要研究方向^[12]。联邦遗忘学习通过移除用户数据影响满足法规要求，但需平衡算法效率与性能^[13]。联邦遗忘学习旨在安全移除共享模型中的用户信息，面临知识渗透与一致性维护等挑战。

在联邦遗忘学习领域，现有研究主要聚焦于提升再训练效率和最小化性能损失。部分研究引入区块链机制提升可追溯性与可信性。如文献[14]提出结合区块链与联邦学习的框架，通过不可篡改的记录机制确保遗忘过程的认证性与高效性，增强模型更新的透明度与安全性。Liu 等人^[15]提出了基于历史参数更新的校准方法，通过重建未学习模型以加速遗忘过程。Wang 等人^[16]创新性地利用卷积神经网络通道的类别区分特性，提出基于 TF-IDF 的剪枝微调策略。Baumhauer 等人^[17]开发了可分解集成模型的线性滤波反学习方法，但其局限于逻辑回归层的操作可能引发中间层参数泄露。FedCSA^[18]框架通过数据聚类切片训练子模型，有效提升了遗忘准确性。KNOT^[19]采用异步集群训练机制降低重训练耗时。

相比于中心化联邦遗忘，去中心化联邦环境下的遗忘机制尚缺乏系统性研究。Gong 等人^[20]提出基于变分贝叶斯方法，构建了固定拓扑下的分布式推理框架，结合本地自由能优化与 gossip 通信，实现了高效遗忘。BlockFUL^[21]则引入区块链变体结构与变色哈希(CH)技术，以降低模型删除操作的计算与共识开销。然而，这两种方法分别依赖于静态通信结构或区块链基础设施，在资源受限或拓扑动态变化的场景下适应性有限。相比之下，本文提出的 CDFU 框架适用于更通用的 DFL 环境，在保证效率的同时具备更强的灵活性与可推广性。在 DFL 中，模型参数通过分布式通信持续扩散，导致遗忘请求涉及的客户端范围更广，需多方协同重训练，显著增加计算与通信负担。同时，算力异构、带宽差异及数据非独立同分布(Non-IID)等问题进一步加剧了模型收敛难度，使拓扑优化成为关键挑战。

本文提出了一种新颖的基于聚类的去中心化联邦遗忘方法 CDFU，通过高效的客户端划分和拓扑学习提升系统性能。主要贡献如下：

1) 综合考虑计算能力和带宽资源异构，以及数据分布异质性，设计了一种基于 K-means^[22]的分层聚类算法(HCK)，实现客户端的智能划分。

2) 提出了基于时延优化的拓扑学习算法(LOTL)，构

建具有时间相似性与数据代表性的稀疏通信拓扑，并对拓扑进行优化以提升 Non-IID 场景下的模型收敛速度。

3) 实验结果表明，本方法在多个基准数据集上优于现有方案，在模型精度和收敛速度方面表现突出，为 DFL 场景下的高效遗忘机制提供了新的技术路径。

1 基于聚类的去中心化联邦遗忘方法

1.1 问题描述

整个去中心化联邦学习系统包含多个客户端，表示为 $\mathcal{C} = \{C_i\}_{i \in \mathcal{N}}$ ，其中 $\mathcal{N} = \{1, 2, \dots, N\}$ 。每个客户端 C_i 在其本地数据集 $\mathcal{D}_i$ 上训练本地模型 θ_i 。其本地目标函数定义为^[23]：

$$F_i(\theta_i) \triangleq \frac{1}{|\mathcal{D}_i|} \sum_{\xi \in \mathcal{D}_i} f(\theta_i, \xi) \quad (1)$$

其中 $f(\theta_i, \xi)$ 为单个样本 $\xi = (\mathbf{x}_j, y_j)$ 的损失函数， $\mathbf{x}_j$ 表示特征向量， y_j 为标签。系统全局优化目标为：

$$F^* \triangleq \min_{\theta \in \mathbb{R}^d} F(\theta) \triangleq \frac{1}{n} \sum_{i=1}^N F_i(\theta) \quad (2)$$

在第 t 轮训练中，客户端通过梯度下降更新本地模型：

$$\theta_i(t) = \tilde{\theta}_i(t) - \eta \nabla F_i(\tilde{\theta}_i(t)) \quad (3)$$

其中 $\tilde{\theta}_i(t)$ 表示第 t 轮聚合后的模型参数， η 是学习率。客户端通过点对点(P2P)通信与邻居客户端 $\mathcal{H}_i$ 交换参数，然后执行模型聚合：

$$\tilde{\theta}_i(t+1) = \frac{1}{|\mathcal{H}_i|+1} \left[\sum_{j \in \mathcal{H}_i} \theta_j(t) + \theta_i(t) \right] \quad (4)$$

在 DFL 中，所有客户端和通信链路可以形成一个有向连通图 $G(\mathcal{C}, \mathcal{E})$ ，其中 $\mathcal{C}$ 表示客户端的集合， $\mathcal{E}$ 表示链路的集合。系统网络拓扑结构可以用一个权重矩阵 $\mathbf{W} \in [0, 1]^{N \times N}$ 来表示， $\mathbf{W}_{ij} > 0$ 表示客户端 C_j 到客户端 C_i 的通信连接权重。通信复杂度由最大入度 $d_{\text{in},m}(\mathbf{W})$ 和最大出度 $d_{\text{out},m}(\mathbf{W})$ 决定(下文 $d_m(\mathbf{W})$ 简称为 d_m)，表示如下：

$$\begin{aligned} d_m(\mathbf{W}) &= \max \{d_{\text{in},m}(\mathbf{W}), d_{\text{out},m}(\mathbf{W})\} \\ &= \max \left\{ \max_i \sum_{j=1}^N \mathbb{I}[\mathbf{W}_{ij} > 0], \max_i \sum_{j=1}^N \mathbb{I}[\mathbf{W}_{ji} > 0] \right\} \end{aligned} \quad (5)$$

在拓扑设计中，更少的通信链路可降低通信成本，但可能减慢收敛速度，需合理权衡两者关系。

考虑到设备的带宽异构性，链路 e_{ij} 的有效带宽为：

$$b_{i,j} = \min \left\{ \frac{b_{out,i}}{d_m}, \frac{b_{in,j}}{d_m} \right\} \quad (6)$$

其中 $b_{in,j}$ 和 $b_{out,j}$ 分别表示客户端 C_i 的入站带宽和客户端 C_j 出站带宽。系统带宽矩阵 $\mathbf{B} = \{b_{i,j}\} \in \mathbb{R}^{N \times N}$ 具有非对称性, 所以 $b_{i,j} \neq b_{j,i}$ 。

机器遗忘学习是指通过算法消除特定训练数据点对已训练模型的影响^[24]。在去中心化联邦学习场景中, 设全局数据集为 $\mathcal{D} = \bigcup_{i \in \mathcal{N}} \mathcal{D}_i$ 。本文使用 $\mathcal{L}$ 算法学习一个参数为 Θ 的全局模型。当客户端 C_i 发起针对局部数据集 $\mathcal{D}_o \in \mathcal{D}_i$ 的遗忘请求时, 再使用遗忘学习算法 $\mathcal{U}$ 生成一个已消除数据 $\mathcal{D}_o$ 影响的新模型^[25], 理想情况下, 新模型应尽可能接近于直接在 $\mathcal{D} \setminus \mathcal{D}_o$ 上训练的结果, 即:

$$\mathcal{U}(\mathcal{L}(\mathcal{D}), \mathcal{D}_o) \sim \mathcal{L}(\mathcal{D} \setminus \mathcal{D}_o) \quad (7)$$

遗忘学习算法的设计聚焦两目标: 一是提升遗忘效率, 缩短时间开销; 二是缩小遗忘前后模型性能差距。在 DFL 中执行遗忘, 需考虑通信开销与计算资源异构性, 复杂性远超集中式联邦学习。核心挑战在于数据删除后高效重训练, 充分利用分布式

资源, 同时应对非独立同分布数据和复杂网络拓扑的影响。本文旨在计算、通信与数据异构性间寻求最优平衡, 实现高效稳定的遗忘过程。

1.2 CDFU 整体架构

为提升去中心化联邦学习中的遗忘效率, CDFU 通过合理划分客户端, 使各集群基于本地数据进行独立并行训练, 从而加速遗忘重训练过程。然而, 简单随机分配难以充分利用和优化系统资源。例如, 若计算能力差异大的客户端被分至同一集群, 慢速客户端可能会显著拖慢整体收敛速度, 降低训练效率。此外, 通信拓扑结构和数据异质性也显著影响收敛效率: 多 P2P 连接若未受控, 易引发通信延迟与带宽资源浪费; 随机分配可能导致数据分布不均, 削弱局部模型的泛化能力, 进而影响全局模型性能; 同时, 带宽异构性进一步加剧通信协调的复杂性, 需综合优化策略以提升整体表现。

为应对这些挑战, 本文提出了 CDFU 算法, 整体架构如图 1 所示:




图1 CDFU 整体架构

Fig.1 Overall architecture of CDFU

CDFU 主要包含以下三个步骤:

1) 客户端聚类: 先根据客户端数据分布差异性, 将客户端划分为多个大组, 再根据关键时间将

大组划分成多个小组, 并将这些小组分配到各自的集群。

2) 集群通信拓扑的构建与并行训练: 使用

LOTL 算法为每个集群构建一个高效的通信拓扑并进行优化。客户端在本地训练模型，定期与集群内的邻居进行模型交换，集群之间互不影响。训练完成后，采用多数投票机制进行性能测试。

3) 遗忘请求处理与局部重训练：当某客户端发出遗忘请求并删除相应数据后，CDFU 仅对该客户端所属集群内的所有客户端进行重训练，而无需影响其他集群，从而避免全局范围内的冗余计算。

1.3 基于 K-means 的分层聚类算法

客户端聚类机制是提升联邦遗忘学习效率的核心。在异步联邦学习场景中，KNOT 根据传输时间和模型偏差计算匹配评分，将评分相近的客户端聚成一类，以加速异步联邦遗忘学习的收敛。然而，KNOT 并未考虑到客户端的计算时间。在 DFL 架构中，由于协调器的带宽远低于 CFL 场景下服务器的带宽，需尽量减少客户端与协调器之间的直接模型传输，以降低通信开销。此外，客户端数据的 Non-IID 特性要求集群内部与全局数据分布近似，以确保重训练阶段的预测精度。为此，本文提出分层聚类算法(HCK)，综合考虑计算、通信能力和数据分布，实现高效且鲁棒的客户端划分。

给定 N 个客户端，需将其划分为 K 个互斥集群 $\mathcal{K} = \{1, 2, \dots, K\}$ 。客户端聚类结果由 $\mathbb{L} = \{L_k\}_{k \in \mathcal{K}}$ 表示，其中 L_k 表示集群 k 的客户端集合。每个轮次客户端的时间消耗 t_i 包含训练时间 $t_{cp,i}$ 和传输时间 $t_{cm,i}$ 。客户端的训练时间和其算力有关，而传输时间跟其邻居数量和带宽大小都有关， t_i 可以表示为：

$$t_i = t_{cp,i} + \frac{M}{\min \left\{ b_{in,i}, \min_{j \in \mathcal{H}_i} b_{out,j} \right\} / d_m} \quad (8)$$

其中 d_m 是邻居客户端的数量， M 是传输的模型大小。所有客户端的训练时间表示为 $T_{cp} = \{t_{cp,i}\}_{i \in \mathcal{N}}$ ，所有链路传输时间表示为 $T_{cm} = \{t_{cm,ij}\}_{i,j \in \mathcal{N}}$ 。链路 e_{ij} 的时间消耗包含了传输时间和传入客户端的模型训练时间，公式如下：

$$t_{ij} = t_{cp,j} + t_{cm,ij} \quad (9)$$

若集群中客户端之间的 epoch 时间相近，则客户端的平均等待时间较短，集群模型也能更快收敛。在执行聚类时，每个轮次中客户端的训练时间通常是固定的，而传输时间无法提前确定，因为尚未进行客户端划分和拓扑构建。然而客户端的传输时间下限是已知的，可以表示为 $b_{out,i} / d_m$ 。因此，可以选择时间波动范围较大的因素进行聚类，以最大程度减少集群内

的等待时间，定义关键时间为：

$$t_i = \begin{cases} t_{cp,i}, & \text{if } \max_{j_1, j_2 \in \mathcal{N}} (t_{cp,j_1} - t_{cp,j_2}) \geq \max_{j_3, j_4 \in \mathcal{N}} (t_{cm,j_3} - t_{cm,j_4}), \\ t_{cm,i}, & \text{else.} \end{cases} \quad (10)$$

客户端 C_i 的本地数据分布表示为 $\pi_i \in [0, 1]^{1 \times R}$ ，其中 R 是全局的数据类别总数。客户端在类别 r 上的本地数据占比定义为 π_{ir} ，客户端之间数据分布差异通过改进的 JS(Jensen-Shannon)散度计算：

$$D_{i,j} = \frac{1}{2} \sum_{r=1}^R \pi_{ir} \log_2 \left(\frac{\pi_{ir}}{\frac{1}{2}(\pi_{ir} + \pi_{jr}) + \epsilon} \right) + \frac{1}{2} \sum_{r=1}^R \pi_{jr} \log_2 \left(\frac{\pi_{jr}}{\frac{1}{2}(\pi_{ir} + \pi_{jr}) + \epsilon} \right) \quad (11)$$

与标准 JS 散度相比，我们的改进在于在分母中引入正则化项 $\epsilon = 1.0 \times 10^{-5}$ ，以避免稀疏分布下分母为 0 和分母接近零导致的数值不稳定问题。

HCK 算法通过两步实现客户端智能划分：数据感知粗聚类和时间感知细粒度分组。首先，粗聚类基于数据分布确保集群内数据均衡；随后，细粒度分组根据计算能力和带宽优化集群内时间同步性。

1) 数据感知粗聚类：为应对 Non-IID 问题，HCK 首先通过改进的 JS 散度计算客户端间数据分布差异，得到每个客户端的度量矩阵 $D_i \in [0, 1]^{1 \times N}$ 。基于平衡 K-means 算法，以 D_i 为聚类因素将客户端划分为若干个大组，确保每个大组内部客户端的数据分布相似，奠定集群数据均衡的基础。

2) 时间感知细粒度分组：在粗聚类的基础上，HCK 根据客户端的关键时间 t_i 对每个大组内的客户端进行降序排序，通过等分法将每个大组划分为 K 个时间均衡的小组确保小组内时间接近。随后，将各大组中排名第 k 的小组分配至集群 L_k ，确保集群内客户端的关键时间相似，减少同步等待时间。

平衡机制及其收敛分析：HCK 通过分层设计平衡计算能力、带宽和数据分布：第一步优化数据分布，第二步统一关键时间。如图 1 所示，HCK 划分的集群数据分布均衡，客户端关键时间相近，有利于加速模型训练和遗忘重训练。分层设计的优势在于将数据分布均衡和时间同步目标解耦，避免了多目标优化中权重选择的难题。第一步的粗聚类优化数据分布，减

少 Non-IID 问题对模型收敛的影响。K-means 算法已证明在有限步内收敛到局部最优解^[22]。在上一步优化模型的收敛性的基础上,细粒度分组通过关键时间统一计算能力和带宽,确保集群内客户端时间消耗相近,降低同步等待开销。关键时间作为时间维度的统一量化指标,其优化效果可通过时间方差最小化来证明。设集群 k 内客户端的关键时间为 t_i' , 则 HCK 的时间优化目标是使平均集群关键时间方差最小化:

$$\overline{\Delta^2} = \frac{1}{K} \sum_k \Delta_k^2 = \frac{1}{K} \sum_k \frac{1}{N_k} \sum_{i=1}^{N_k} (t_i' - \bar{t}_k')^2 \quad (12)$$

其中 N_k 为集群 k 的客户端数量, $\bar{t}_k'$ 为集群 k 的平均关键时间。相比随机划分, HCK 的分配策略理论上能显著降低 $\overline{\Delta^2}$, 从而加速整体训练效率。实验结果也是如此, Random 方法的 $\overline{\Delta^2}$ 是 HCK 的 1.87 倍。

与现有工作相比, HCK 算法在客户端聚类中展现出显著创新性。K-means 和 K-means++ 聚焦簇内方差最小化, 难以应对 DFL 场景下的时间异构性和 Non-IID 数据挑战。KNOT 通过匹配评分实现异步聚类, 但忽视计算时间影响且未优化数据分布均衡性。HCK 则通过分层设计解耦数据分布和时间同步: 粗聚类基于改进 JS 散度优化数据均衡, 细粒度分组通过关键时间统一计算能力和带宽, 降低同步等待开销。

1.4 基于时延优化的拓扑学习算法

在完成客户端到集群的分配后, 客户端之间尚未建立连接, 接下来需为每个集群学习一个通信拓扑。对于每个集群 k 及其混合矩阵 $\mathbf{W}_k$, 本文引入邻域异质性概念^[26], 以衡量客户端邻域中加权聚合梯度(由 $\mathbf{W}_k$ 加权)与全局平均梯度之间的期望距离, 该距离定义如下:

$$\sum_{k \in \mathcal{K}} \frac{1}{|L_k|} \sum_{i \in L_k} \mathbb{E} \left\| \sum_{j \in L_k} \mathbf{w}_{kij} \nabla F_j(\theta, \xi_j) - \frac{1}{n} \sum_{j \in L_k} \nabla F_j(\theta, \xi_j) \right\|_2^2 \leq \bar{\tau}^2 \quad (13)$$

其中 $\bar{\tau}^2$ 是一个常数。

在联邦学习中, 数据异质性(如标签倾斜)导致客户端数据分布差异。假设存在 $\Lambda > 0$ 和 $\sigma_i^2 > 0$, 分别约束标签分布偏差和客户端梯度方差, 邻域异质性 $\bar{\tau}^2$ 可分解为偏差项和方差项, 公式如下:

$$\bar{\tau}_k^2 = \frac{R\Lambda}{|L_k|} \sum_{r=1}^R \sum_{i \in L_k} \left(\sum_{j \in L_k} \mathbf{w}_{kij} \pi_{jr} - \frac{1}{|L_k|} \sum_{j \in L_k} \pi_{jr} \right)^2 + \frac{\sigma_{\max}^2}{|L_k|} \mathbf{W}_k - \frac{\mathbf{1}\mathbf{1}^T}{|L_k|^F} \quad (14)$$

其中, $\sigma_{\max}^2 = \max_{i \in \mathcal{N}} \sigma_i^2$ 表示所有客户端梯度方差的最大值, 衡量数据异质性对方差项的影响。偏差项在数据独立同分布(IID)时最小。当集群 k 内的拓扑是全连接拓扑, 也就是 $\mathbf{W}_k = \frac{\mathbf{1}\mathbf{1}^T}{|L_k|}$ 时, 方差项是最小的。

但集群内的全连接拓扑会带来高昂的通信成本。因此可以为每一个集群构建一个稀疏拓扑, 降低开销并加速收敛。

对于集群 k , 目标是学习一个拓扑 $\mathbf{W}_k$, 使得公式(15)中的 τ_k^2 最小化。优化目标可以表示成以下公式:

$$\min_{\mathbf{W}_k \in \mathcal{S}} \left\{ g(\mathbf{W}_k) \triangleq \frac{1}{|L_k|} \left\| \mathbf{W}_k \Pi_k - \frac{\mathbf{1}\mathbf{1}^T}{|L_k|} \Pi_k \right\|_F^2 + \frac{\lambda}{|L_k|} \mathbf{W}_k - \frac{\mathbf{1}\mathbf{1}^T}{|L_k|^F} \right\} \quad (15)$$

其中 $\mathcal{S} \triangleq \{\mathbf{W}_k \in [0,1]^{|L_k| \times |L_k|} : \mathbf{W}_k \mathbf{1} = \mathbf{1}, \mathbf{1}^T \mathbf{W}_k = \mathbf{1}^T\}$, 是双随机矩阵集合。 $\Pi_k \in [0,1]^{|L_k| \times R}$ 表示集群 k 中所有客户端的数据类别比例。 $\lambda = \frac{\sigma_{\max}^2}{R\Lambda}$ 平衡偏差和方差实践中作为可调参数。

基于 Frank-Wolfe 的稀疏拓扑学习算法(STL-FW)适合在有限原子集凸包上寻找稀疏解^[27]。该方法通过构建稀疏拓扑, 有效平衡了去中心化随机梯度下降(D-SGD)的通信成本与收敛速度。然而, STL-FW 考虑的只是宏观的通信预算, 并未考虑细粒度的通信时间因素, 其收敛速率在带宽异质性显著时易受高时延链路制约。为此, 本文提出了拓扑学习与优化算法(LOTL), 构建稀疏拓扑以后再进行优化, 以提升训练效率。其中优化的主要思路是: 优先移除时延最大的链路, 并在确保整体连通性和每个客户端局部连通度的条件下, 加速本地训练收敛。必要时, 通过删除与高时延链路关联的其他链路, 间接降低最大时延。设定超参数 $c \in [0,1]$, 用来控制删除上限。

LOTL 算法描述见算法 1。第一阶段旨在生成每个集群的初步稀疏拓扑。对于集群 k , 算法从单位矩阵初始化拓扑 $\hat{\mathbf{W}}_k^{(0)}$, 通过迭代最小化线性目标

$g(\mathbf{W}_k)$ 。每轮迭代计算当前拓扑下目标函数的梯度 $\nabla g(\hat{\mathbf{W}}_k^{(d)})$ ，然后利用匈牙利算法求解一个指派问题^[28-29]以确定新的置换矩阵 $\mathbf{P}_k^{(d+1)}$ ，再通过线性搜索确定当前拓扑 $\hat{\mathbf{W}}_k^{(d)}$ 与 $\mathbf{P}_k^{(s+1)}$ 的最佳组合，逐步更新拓扑（详见算法第 1-6 行）。由于置换矩阵每行和每列仅含一个 1，每次迭代中每个客户端至多增加一个传入邻居和传出邻居，参数 d_m 调控拓扑稀疏性，决定了拓扑的链路数量上限。

第二阶段通过优化通信拓扑以减少通信延迟。首先将权重拓扑 $\mathbf{W}_k$ 转换成通信拓扑图 G_k ，并根据带宽、计算时间和模型大小计算各链路通信时延，按降序排列（第 7-9 行）。随后计算客户端删除上限 $Q = \{Q_i\}_{i \in L_k}$ 和整个集群删除上限

$$Q'_k = \left\lfloor c \cdot \sum_{i \in L_k} \sum_{j \in L_k} G_{kij} \right\rfloor \quad (\text{第 10 行}), \text{ 其中客户端 } C_i \text{ 的删除上限 } Q_i = \left\lfloor c \cdot \sum_{j \in L_k} G_{kij} \right\rfloor。$$

Q_i 和 Q'_k 分别控制客户端 C_i 和集群的链路删除的程度。当删除链路数量不超过上限时，计算当前最大时延链路集 $E_{\max}$ （第 12 行）。在确保连通性的前提下，优先移除时延最大的链路（isConnectivity 函数在每次删边前检查连通性，避免出现孤立节点或集群分裂）。对于当前最大时延链路 e ，若未超上限且移除后仍连通，则删除并更新有关参数（第 14-19 行）；若 $E_{\max}$ 已经没有可删除的链路，则检查关联的次级链路，若移除可间接减少最大时延，则执行删除（第 22-28 行）。此过程循环执行，直至删除上限或 G_k 拓扑稳定。随后，将集群的通信图 G_k 转换为双重随机矩阵 $\hat{\mathbf{W}}_k$ ，作为模型聚合权重，满足联邦学习中的拓扑约束。最后返回合并后的所有客户端的模型聚合权重 $\hat{\mathbf{W}}$ 。通过此策略，LOTL 可以有效削减高时延链路的影响，提升系统的通信效率与模型收敛速度。

LOTL 通过优化稀疏拓扑显著提升去中心化联邦遗忘学习的模型收敛性。该算法在保持拓扑连通性的前提下，优先删除高时延链路，从而降低通信延迟，减弱邻域异质性对梯度聚合的干扰。基于 D-SGD 的收敛特性，LOTL 所构建的稀疏拓扑有效提升了收敛速率：一方面，优化后的连通拓扑（其 Laplacian 矩阵的第二小特征值大于 0）保障了全局梯度的可达性；另一方面，通信延迟的降低减小了客户端间的梯度差

异，使模型更快趋于全局最优。实验 2.3 进一步验证 LOTL 显著加速了模型训练和遗忘重训练过程。

LOTL 算法与现有拓扑构建方法的差异在于其对时延优化的细粒度处理。STL-FW 通过 Frank-Wolfe 算法生成稀疏拓扑，关注宏观通信预算，但忽视链路时延异构性，导致高时延场景下收敛效率受限。Random 和 Full 方法因随机性过强或开销过高难以平衡效率与性能。相比之下，LOTL 在生成稀疏拓扑后，通过超参数 c 控制删除上限，优先移除高时延链路，并引入次级链路策略降低最大时延影响。在保持连通性的前提下，LOTL 显著减少通信延迟，凸显其在异构网络中的优势。

算法 1 LOTL

输入： 客户端聚类结果 $\mathbb{L} = \{L_k\}_{k \in \mathcal{K}}$ ，类别比例 $\Pi \in [0, 1]^{N \times R}$ ，带宽矩阵 $\mathbf{B}$ ，训练时间 $T_{cp} = \{t_{cp,i}\}_{i \in \mathcal{N}}$ ，迭代次数 d_m ，模型大小 M ，超参数 c ，超参数 λ 。

输出： 所有客户端的通信拓扑 $\hat{\mathbf{W}}$

```

1. for each  $k = 1, \dots, K$  do
2.    $\hat{\mathbf{W}}_k^{(0)} \leftarrow I_{|L_k|}$ 
3.   for each  $d = 0, \dots, d_m$  do
4.      $\mathbf{P}_k^{(d+1)} \leftarrow \operatorname{argmin}_{\mathbf{P}_k \in \mathcal{A}} \left\langle \mathbf{P}_k, \nabla g(\hat{\mathbf{W}}_k^{(d)}) \right\rangle$ 
5.      $\gamma^{(d+1)} \leftarrow \operatorname{argmin}_{\gamma \in [0, 1]} g\left((1-\gamma)\hat{\mathbf{W}}_k^{(d)} + \gamma\mathbf{P}_k^{(d+1)}\right)$ 
6.      $\hat{\mathbf{W}}_k^{(d+1)} \leftarrow (1-\gamma^{(d+1)})\hat{\mathbf{W}}_k^{(d)} + \gamma^{(d+1)}\mathbf{P}_k^{(d+1)}$ 
7.    $G_k \leftarrow \operatorname{generateGraph}(\hat{\mathbf{W}}_k^{(s+1)})$ 
8.    $\bar{T}_k \leftarrow \operatorname{calLinkTimes}(G_k, \mathbf{B}, T_{cp}, M)$ 
9.    $\operatorname{sort}(\bar{T})$ 
10.   $Q, Q' \leftarrow \operatorname{calQuota}(G_k, c)$ 
11.  While  $Q' > 0$  do
12.     $E_{\max} \leftarrow \operatorname{findMaxEdges}(\bar{T})$ 
13.    // 优先考虑最大时延链路
14.    for  $e \in E_{\max}$  do
15.      if  $\operatorname{checkQuota}(Q, e) \&\& \operatorname{isConnectivity}(G_k)$  then
16.        remove edge  $e$  from  $G_k$ 
17.        update  $Q, Q'$ 
18.        update  $\bar{T}$  and sort in descending order
19.      break
20.    if  $G_k$  has changed in this round, continue
21.    // 考虑与  $E_{\max}$  有连接的非最大时延链路
22.    for  $t_e \in \bar{T}$  do
23.      if  $\operatorname{checkQuota}(Q, e) \&\& \operatorname{isConnectivity}(G_k)$  then
24.        if  $\operatorname{isReduceEmax}(G_k, \mathbf{B}, T_{cp}, M, e)$  then

```


25. remove edge e from G_k
26. update Q, Q'
27. update $\bar{T}$ and sort in descending order
28. break
29. if G_k has not changed in this round, break
30. $\hat{W}_k \leftarrow \text{generateTopo}(G_k)$
31. $\hat{W} \leftarrow \hat{W} \cup \hat{W}_k$

1.5 算法复杂度分析

HCK 的粗聚类计算 R 个数据类别的 JS 散度, 复杂度 $O(N^2R)$, 聚类复杂度 (K 个簇, I 次迭代) 为 $O(NIK)$, 细分组排序为 $O(K \cdot N_k \log N_k)$ 。对于每个集群, LOTL 算法生成拓扑复杂度 $O(d \cdot N_k^3)$, 优化阶段排序复杂度 $O(E_k \log E_k)$, 边删除复杂度 $O(Q'_k \cdot N_k(1+d))$ 。又因为 $E_k = d \cdot N_k$, $N_k \approx N/K$, 忽略部分常数, 总体复杂度可表示为 $O(N^2R + N^3d/K^2) = O(N^3)$ 。实际的实验中, CDFU 的计算开销和耗时较小, 基本可以忽略。

2 实验结果与分析

2.1 实验设置

在本研究中, 我们选取了 CIFAR-10^[30]、MNIST^[31]和 CIFAR-100^[32]三个数据集开展实验。实验采用归一化的 LeNet^[33]模型进行训练, 设定学习率为 0.008, 批量大小为 20。参照文献[2]的方法, 我们将数据集分配至 90 个客户端, 其中每个客户端持有 2 个随机选择的类别。每个方法在同一时间随机删除某些客户端的部分数据。在涉及聚类的方法中, 集群数量设定为 $K=3$ 。根据文献[26]的参数配置, 超参数 λ 取值为 0.1。为确保实验结果的可靠性和公平性, 每组实验在同一时间点删除相同数量的数据样本, 每种方法取多个随机种子运行多次取平均值。2.2、2.3 和 2.5 小节采用 CIFAR-10 数据集进行实验, 2.4 小节采用多个数据集。实验所使用的内部服务器配备了两块 NVIDIA V100 Tensor Core GPU (每块 32 GB 显存)、96 个 CPU 核心以及 256 GB 的内存。

2.2 聚类方法对比实验

为了体现 HACK 算法在数据异质环境下的性能, 将其与其他五种聚类算法进行对比, 分别是 Random、No-Clustering、K-means、K-means++^[34]和 KNOT。Random 算法将所有客户端随机均分为 K

个集群, No-Clustering 则不进行划分, 将所有客户端视为单一集群, 类似完全同步训练。K-means 通过最小化簇内方差形成 K 个集群, 提供数据驱动的划分; 而 K-means++通过优化初始中心选择提升稳定性, 进一步适应数据异质环境。对 K-means 和 K-means++, 由于本文聚类目标并非追求集群内数据分布相似性, 而是实现集群间数据分布的均衡性, 因此以关键时间作为聚类依据。KNOT 通过客户端分簇并只在簇内聚合以降低重训练开销, 特别适用于异步场景。KNOT 基于匹配评分将客户端分为 K 个集群, 鉴于协调器的带宽限制, 本文使用关键时间计算匹配评分。训练总时间为 6000 秒, 均使用 Random-d (随机生成拓扑, $d_m=10$) 算法生成集群拓扑。实验结果如图 2 所示。




图 2 不同聚类算法的准确率比较

Fig.2 Comparison of Clustering Method Accuracy

实验结果表明 No-Clustering 作为无聚类的基准方案, 其表现最差, 主要原因在于遗忘请求发生时, 所有客户端均需进行重训练, 导致训练开销较大。KNOT、K-means 和 K-means++的准确率相近, 与 Random 的差距并不明显, 表明这些方法在 Non-IID 场景下对数据分布和时间异构性的优化不足, 改进空间有限。HACK 在整个训练过程中始终保持最高的准确率, 显著优于其他方法。此外, 在遗忘数据后, 该方法能够迅速恢复准确率, 进一步验证了其结合粗聚类与细粒度分组策略的有效性, 有助于提升并稳定模型性能。

2.3 拓扑构建方法对比实验

这一节的实验分为两部分, 分别是超参数 c 的确定和拓扑构建方法对比。首先, 需要通过实验分析超参数 c 对模型性能和训练效率的影响。 c 控制

LOTL 算法的链路删除上限,影响通信拓扑及时延优化。实验中取 $d_m=10$,总训练时间为 4000 秒。均采用 HCK 算法进行客户端聚类。实验分别设置 c 为 $\{0, 0.1, 0.2, 0.3, 0.4, 0.5, 0.6\}$,并记录模型准确率和集群 epoch 时间的平均减少比重。

实验结果如表 1 所示,当 $c=0$ 时未移除任何链路,导致性能较差。随着 c 增加,epoch 时间节约比重显著提升,表明适当移除高时延链路能够有效降低 epoch 时间。在准确率方面, $c=0$ 时的基准值为 0.577,随着 c 增加准确率总体提升,在 $c=0.5$ 达峰值 0.629 (较基准提升约 9.0%),但 $c=0.6$ 时有所降低。分析表明, c 较小时($c<0.5$),时间优化不足; c 较大时($c>0.5$),高时延链路已基本移除,继续删除导致梯度聚合效率下降,epoch 时间优化增益递减。综合性能与训练效率, $c=0.5$ 实现最佳平衡,后续实验将采用此值进行综合对比验证。

表 1 不同 c 值对 LOTL 算法准确率与训练效率的影响

Table 1 Impact of different c values on the accuracy and training efficiency of the LOTL algorithm.

c	Accuracy	Proportion of epoch time reduction (%)
0	0.577	0
0.1	0.614	7.51
0.2	0.559	15.9
0.3	0.587	21.8
0.4	0.590	31.8
0.5	0.629	40.9
0.6	0.61	42.7

接下来通过实验对比了四种拓扑构建方法在联邦学习中的性能,包括 Random-d、Full、STL-FW 和 LOTL。Random-d 为每个客户端随机分配 d 个入度邻居和 d 个出度邻居,进行对比实验时, $d=d_m$; Full 算法采用全连接拓扑,通信开销高;STL-FW 生成稀疏拓扑,平衡通信成本和收敛性。实验固定 $d_m=10$,训练总时间设置为 6000 秒,实验结果如表 2 所示:

表 2 不同拓扑构建算法的准确率

Table 2 Accuracy of different topology construction algorithms

Method	Accuracy
Full	0.553
Random	0.596
STL-FW	0.614
LOTL	0.648

Random-d 和 Full 方法的准确率分别为 0.596 和 0.553,性能较低,表明其难以适应数据异质性。STL-FW 提升至 0.614,其构建的稀疏拓扑能够有效降低客户端邻域异质性,促进模型收敛。LOTL 进一步达到 0.648,较 STL-FW 提升约 5.54%,说明其时延优化策略在异质性场景下效果显著。

2.4 综合对比实验

为全面评估 CDFU 方法的性能,本文在 CIFAR-10 和 SVHN 数据集上与其他五种方法进行对比。其中每个方法都是聚类算法和拓扑构建方法的组合。实验设置 $d_m=5$ 和 $d_m=10$ 模拟不同的通信复杂度,结果如表 3 和表 4 所示,加粗表示最优值。

表 3 CIFAR-10 数据集上不同方法的准确率

Table 3 Accuracy of different methods on the CIFAR-10 dataset

Method	$d_m=5$	$d_m=10$
Random/Full	0.412	0.450
Random/Random-d	0.454	0.514
K-means/STL-FW	0.513	0.523
K-means++/STL-FW	0.492	0.515
KNOT/STL-FW	0.497	0.539
CDFU(HCK/LOTL)	0.589	0.656

表 4 SVHN 数据集上不同方法的性能表现

Table 4 Accuracy of different methods on the SVHN dataset

Method	$d_m=5$	$d_m=10$
Random/Full	0.689	0.713
Random/Random-d	0.833	0.856
K-means/STL-FW	0.839	0.850
K-means++/STL-FW	0.844	0.841
KNOT/STL-FW	0.849	0.847
CDFU(HCK/LOTL)	0.858	0.877

表 5 CIFAR-100 数据集上不同方法的性能表现

Table 5 Accuracy of different methods on the CIFAR-100 dataset

Method	$d_m=5$	$d_m=10$
Random/Full	0.184	0.288
Random/Random-d	0.285	0.224
K-means/STL-FW	0.348	0.374
K-means++/STL-FW	0.360	0.373
KNOT/STL-FW	0.356	0.373
CDFU(HCK/LOTL)	0.379	0.397

综合来看,Random/Full 在三个数据集上的准确率都是最低,表明全连接拓扑会导致过大的时间消

耗,显著降低了模型的收敛速率。Random/Random-d 方法的训练效果比前者要好,但性能不稳定。K-means/STL-FW、K-means++/STL-FW 和 KNOT/STL-FW 准确率提升显著,由于这三个聚类方法的聚类算法性能相近,所以这三者之间相差不大。CDFU 在两数据集上表现最佳,较 STL-FW 基线方法平均提升 21.3%(CIFAR-10)、2.7%(SVHN)和 6.6%(CIFAR-100)。CIFAR-10 数据集上的效果尤为突出,归因于其复杂异质特征更符合 CDFU 的优化优势。这些结果验证了 CDFU 通过高效的客户端划分和构建低时延的通信拓扑,有效增强了模型在去中心化联邦场景下的遗忘学习能力。

2.5 其他实验

参数 K 的敏感性分析实验: 为评估 HCK 算法中聚类数量 K 对性能的影响,我们开展了参数敏感性分析实验,旨在为参数选择提供依据,并探索 K 对模型准确率的潜在影响。实验在 K 取值范围为 1 至 5 的条件下进行。实验结果如下表:

表 6 不同 K 值对 CDFU 方法准确率与训练效率的影响

Table 6 The impact of different K values on the accuracy and training efficiency of the CDFU method.

K	1	2	3	4	5
Accuracy	0.592	0.590	0.646	0.647	0.650

结果显示,当 $K=1$ 时,单一集群无法有效处理 Non-IID 数据,性能较低; $K=2$ 时,准确率有所下降,可能因划分过粗未能充分利用数据分布差异。随着 K 增至 3,准确率显著提升,表明适度聚类能更好平衡数据分布与计算负载。 $K=4$ 和 $K=5$ 时,准确率继续提高,但增幅趋于平缓,反映出聚类数量的边际效益递减。实验说明基于分簇的方法是有效的,在 $K>3$ 时都有较好的模型性能(本文取 $K=3$)。

极端 Non-IID 下的性能评估实验: 为验证 CDFU 方法在极端 Non-IID 数据分布下的鲁棒性,我们在 CIFAR-10 数据集上设计了额外的实验,评估每个客户端仅含单一类别数据时的性能。实验结果如表 7 所示。

表 7 极端 Non-IID 下的性能评估

Table 7 Performance Evaluation under Extreme Non-IID Setting.

Method	$d_m=5$	$d_m=10$
Random/Full	0.19885	0.286
Random/Random-d	0.1997	0.261

K-means/STL-FW	0.2481	0.373
K-means++/STL-FW	0.24925	0.349
KNOT/STL-FW	0.27045	0.363
CDFU(HCK/LOTL)	0.2755	0.377

结果表明,CDFU 方法在极端 Non-IID 场景下性能最佳,说明 CDFU 通过分层聚类机制与高效拓扑构建,有效缓解了由单一类别引发的极端异构性挑战,展现出较强的鲁棒性与良好的泛化能力。

3 结束语

本文提出的 CDFU 方法在实际应用中展现出显著潜力,能够有效应对去中心化联邦学习中数据隐私保护与遗忘学习的挑战。该方法尤其适用于资源受限的物联网场景和分布式边缘计算环境,其分层聚类机制与低时延拓扑构建策略不仅显著降低了遗忘重训练成本,还加快了模型的收敛速度,同时保持了优良的性能表现。然而,该方法仍存在一定局限性。目前部分超参数的设置仍依赖经验调优,尚未实现完全自适应,可能限制其在高度异构环境中的泛化能力。未来的研究可重点探索动态环境下的自适应机制,例如在遗忘请求频繁或客户端动态变动(如频繁加入或退出)的场景中,引入在线学习优化参数,或结合预测模型实现拓扑的动态调整,以增强 CDFU 在非稳定环境中的鲁棒性与适应性。

参考文献

- [1] Y. Sun, M. Peng, Y. Zhou, Y. Huang, and S. Mao, "Application of machine learning in wireless networks: Key techniques and open issues," *IEEE Communications Surveys & Tutorials*, vol. 21, no. 4, pp. 3072–3108, 2019.
- [2] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Artificial intelligence and statistics*, PMLR, 2017, pp. 1273–1282.
- [3] 熊世强,何道敬,王振东,杜润萌. 联邦学习及其安全与隐私保护研究综述[J]. 计算机工程, 2024, 50(5): 1-15.
- XIONG Shiqiang, HE Daojing, WANG Zhendong, DU Runmeng. Review of Federated Learning and Its Security and Privacy Protection[J]. Computer Engineering, 2024, 50(5): 1-15.
- [4] A. Lalitha, S. Shekhar, T. Javidi, and F. Koushanfar, "Fully decentralized federated learning," in *Third workshop on bayesian deep learning (NeurIPS)*, 2018.
- [5] S. Augenstein, A. Hard, K. Partridge, and R. Mathews, "Jointly learning from decentralized (federated) and centralized data to mitigate distribution shift," *arXiv preprint arXiv:2111.12150*, 2021.
- [6] 刘伟,马杰,夏玉洁,等.一种基于区块链和梯度压缩的去中心化联邦学习模型[J].郑州大学学报(理学版), 2024, 56(5):47-54.
- Wei Liu, Jie Ma, Yujie Xia, et al. A Decentralized Federated Learning Model Based on Blockchain and Gradient

- Compression. Journal of Zhengzhou University (Natural Science Edition), 2024, 56(5):47-54.
- [7] 周炜,王超,徐剑,等.基于区块链的隐私保护去中心化联邦学习模型[J].计算机研究与发展, 2022, 59(11):2423-2436.
- Wei Zhou, Chao Wang, Jian Xu, et al. Privacy-Preserving and Decentralized Federated Learning Model Based on the Blockchain. Journal of Computer Research and Development, 2022, 59(11): 2423-2436.
- [8] P. Voigt and A. Von dem Bussche, *The EU general data protection regulation (GDPR). A practical guide*. Springer International Publishing, 2017.
- [9] S. of C. D. of J. Office of the Attorney General, "California consumer privacy act (CCPA)." <https://oag.ca.gov/privacy/ccpa>, 2023.
- [10] R. N. Daniel Hounslow, "Japan - data protection overview (JDPO)." <https://www.dataguidance.com/notes/japan-dataprotection-overview>, 2019.
- [11] G. of Canada, "Consumer privacy protection act." 2022. Available: <https://ised-isde.canada.ca/site/innovation-better-canada/en/consumer-privacy-protection-act>
- [12] Y. Cao and J. Yang, "Towards making systems forget with machine unlearning," in *2015 IEEE symposium on security and privacy*, IEEE, 2015, pp. 463-480.
- [13] 王鹏飞, 魏宗正, 周东生, 等. 联邦忘却学习研究综述[J]. 计算机学报, 2024, 47(2): 396-422.
- WANG Pengfei, WEI Zongzheng, ZHOU Dongsheng, et al. A Survey on Federated Unlearning[J]. Chinese Journal of Computers, 2024, 47(2): 396-422.
- [14] Zuo X, Wang M, Zhu T, et al. Federated learning with blockchain-enhanced machine unlearning: A trustworthy approach[J]. IEEE Transactions on Services Computing, 2025.
- [15] G. Liu, X. Ma, Y. Yang, C. Wang, and J. Liu, "Federaser: Enabling efficient client-level data removal from federated learning models," in *2021 IEEE/ACM 29th international symposium on quality of service (IWQOS)*, IEEE, 2021, pp. 1-10.
- [16] J. Wang, S. Guo, X. Xie, and H. Qi, "Federated unlearning via class-discriminative pruning," in *Proceedings of the ACM web conference 2022*, 2022, pp. 622-632.
- [17] T. Baumhauer, P. Schöttle, and M. Zeppelzauer, "Machine unlearning: Linear filtration for logit-based classifiers," *Machine Learning*, vol. 111, no. 9, pp. 3203-3226, 2022.
- [18] Z. Wang et al., "FedCSA: Boosting the convergence speed of federated unlearning under data heterogeneity," in *2023 IEEE intl conf on parallel & distributed processing with applications, big data & cloud computing, sustainable computing & communications, social computing & networking (ISPA/BDCLOUD/SocialCom/SustainCom)*, IEEE, 2023, pp. 388-393.
- [19] N. Su and B. Li, "Asynchronous federated unlearning," in *IEEE INFOCOM 2023-IEEE conference on computer communications*, IEEE, 2023, pp. 1-10.
- [20] Gong J, Simeone O, Kang J. Bayesian variational federated learning and unlearning in decentralized networks[C]//2021 IEEE 22nd International Workshop on Signal Processing Advances in Wireless Communications (SPAWC). IEEE, 2021: 216-220.
- [21] Liu X, Li M, Wang X, et al. Decentralized federated unlearning on blockchain[J]. CoRR, 2024.
- [22] J. Macqueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of 5-th berkeley symposium on mathematical statistics and probability/university of california press*, 1967.
- [23] X. Lian, C. Zhang, H. Zhang, C.-J. Hsieh, W. Zhang, and J. Liu, "Can decentralized algorithms outperform centralized algorithms? A case study for decentralized parallel stochastic gradient descent," *Advances in neural information processing systems*, vol. 30, 2017.
- [24] M. Chen, Z. Zhang, T. Wang, M. Backes, M. Humbert, and Y. Zhang, "When machine unlearning jeopardizes privacy," in *Proceedings of the 2021 ACM SIGSAC conference on computer and communications security*, 2021, pp. 896-911.
- [25] J. Xu, Z. Wu, C. Wang, and X. Jia, "Machine unlearning: Solutions and challenges," *IEEE Transactions on Emerging Topics in Computational Intelligence*, 2024.
- [26] B. Le Bars, A. Bellet, M. Tommasi, E. Lavoie, and A.-M. Kermarrec, "Refined convergence and topology learning for decentralized sgd with heterogeneous data," in *International conference on artificial intelligence and statistics*, PMLR, 2023, pp. 1672-1702.
- [27] M. Jaggi, "Revisiting frank-wolfe: Projection-free sparse convex optimization," in *International conference on machine learning*, PMLR, 2013, pp. 427-435.
- [28] R. Burkard, M. Dell'Amico, and S. Martello, *Assignment problems: Revised reprint*. SIAM, 2012.
- [29] D. F. Crouse, "On implementing 2D rectangular assignment algorithms," *IEEE Transactions on Aerospace and Electronic Systems*, vol. 52, no. 4, pp. 1679-1696, 2016.
- [30] A. Krizhevsky, G. Hinton, et al., "Learning multiple layers of features from tiny images," 2009.
- [31] Y. Netzer, T. Wang, A. Coates, A. Bissacco, B. Wu, A. Y. Ng et al., "Reading digits in natural images with unsupervised feature learning," in *NIPS workshop on deep learning and unsupervised feature learning*, vol. 2011, no. 2. Granada, 2011, p. 4.
- [32] Krizhevsky A, Hinton G. Learning multiple layers of features from tiny images[J]. 2009.
- [33] K. Hsieh, A. Phanishayee, O. Mutlu, and P. Gibbons, "The non-iid data quagmire of decentralized machine learning," in *International conference on machine learning*, PMLR, 2020, pp. 4387-4398.
- [34] Arthur D, Vassilvitskii S. k-means++: The advantages of careful seeding[R]. Stanford, 2006.