

基于自适应模型剪枝的联邦遗忘学习方法研究

马振国^{①②} 和孜轩^③ 孙彦景^{*①②} 王博文^{③④} 刘建春^{⑤⑥} 徐宏力^{⑤⑥}

^①(中国矿业大学计算机科学与技术学院 徐州 221116)

^②(中国矿业大学人工智能学院 徐州 221116)

^③(中国矿业大学信息与控制工程学院 徐州 221116)

^④(中国矿业大学物联网(感知矿山)研究中心 徐州 221116)

^⑤(中国科学技术大学计算机科学与技术学院 合肥 230026)

^⑥(中国科学技术大学苏州高等研究院 苏州 215123)

摘要: 随着物联网(IoT)设备数量的指数级增长和《个人信息保护法》等法规的相继实施,联邦遗忘学习在边缘计算(EC)中已成为保障数据“被遗忘权”的关键技术。然而,边缘节点普遍存在的资源异构性—计算能力、存储容量和网络带宽等差异,导致基于全局统一剪枝策略的类级遗忘方法(遗忘某类训练数据)面临训练效率下降的困境。为了应对上述挑战,该文针对类级遗忘场景,提出了一种基于自适应模型剪枝的联邦遗忘学习框架(FunAMP),通过降低节点之间的等待时间提高模型训练效率。首先,该文建立了模型训练时间、节点资源与模型剪枝比之间的定量关系,并据此给出自适应模型剪枝问题的形式化定义。随后,设计了一种基于贪心策略的剪枝比决策算法,根据每个节点的计算和通信资源为其分配合适的剪枝比,并分析该算法的近似比,为算法性能提供理论保证。接着,确立了一种基于词频-逆文频的相关性指标来衡量模型参数与目标类数据之间的关系,根据该指标和分配的剪枝比将与目标类数据相关的模型参数去除,从而在实现目标类数据遗忘的同时最大限度地降低模型训练时间。实验结果表明, FunAMP在达到相同准确率的情况下,相比现有方法最高可实现11.8倍的加速比。

关键词: 联邦遗忘学习; 资源异构; 自适应模型剪枝; 相关性指标; 性能分析

中图分类号: TN919; TP393

文献标识码: A

文章编号: 1009-5896(2025)11-4515-10

DOI: 10.11999/JEIT250503

CSTR: 32379.14.JEIT250503

1 引言

随着物联网(Internet of Things, IoT)设备数量的指数级增长,越来越多的数据在边缘侧聚集,促使边缘计算(Edge Computing, EC)成为分布式智能的重要载体^[1]。然而,传统集中式机器学习范式因数据隐私泄露风险难以满足边缘场景的需求。针对该问题,联邦学习(Federated Learning, FL)应运而生,其通过“数据不动模型动”的协作机制,在保护数据隐私的前提下实现多节点联合训练^[2],成为边缘智能领域的核心技术。此外,通过避免原始数据的传输,联邦学习能有效降低模型训练的通信开销。借助上述优势,联邦学习目前已在医疗^[3]、金融^[4]和交通^[5]等多个领域得到了广泛的应用。

然而,联邦学习固有的隐私漏洞(如模型反演、成员推理)引起人们对数据隐私保护和主权治

理的关注^[6],即参与联邦学习的用户可能随时退出模型训练并要求服务器去除其数据对模型的贡献(“被遗忘权”)。为实现该目标,国内外目前已达成一定的立法共识,如欧盟的《通用数据保护条例》(General Data Protection Regulation, GDPR)、我国的《数据安全法》和《个人信息保护法》,均明确指出要保障数据的“被遗忘权”。在此背景下,联邦遗忘学习(Federated Unlearning, FU)作为一种新兴技术,旨在保证模型性能的情况下高效去除特定数据对模型的影响^[7],目前已成为边缘智能领域的重要研究方向。与经典联邦学习方法不同,联邦遗忘学习主要包括2个核心阶段:训练阶段、遗忘阶段。联邦遗忘学习的训练阶段与联邦学习的模型训练过程相似,均由服务器协调各节点根据其本地数据对模型进行更新。遗忘阶段则是联邦遗忘学习的专有流程,主要通过梯度上升、模型剪枝等步骤定向去除目标数据的贡献。此外,遗忘阶段有时也会包含模型微调,以恢复因遗忘操作而损失的模型性能。

根据遗忘目标的粒度,联邦遗忘学习可以分为3类:节点级遗忘(删除某个参与节点的所有数据)、类级遗忘(删除某个类别的数据)、样本级遗忘(删

收稿日期: 2025-06-03; 改回日期: 2025-08-05; 网络出版: 2025-09-16

*通信作者: 孙彦景 yjsun@cumt.edu.cn

基金项目: 中央高校基本科研业务费专项资金(XJ2025012301), 深圳市科技计划(KCXFZ20240903094204007)

Foundation Items: The Fundamental Research Funds for the Central Universities (XJ2025012301), Shenzhen Science and Technology Program (KCXFZ20240903094204007)

除某个特定的样本数据^[8]。对于类级遗忘场景,一种简单的方法是利用除目标类之外的剩余数据从头训练(Retrain from Scratch)模型^[9]。这种方法虽然能剥离目标类数据的贡献,但会导致高昂的计算成本,不适用于资源有限的边缘节点^[10]。为此,文献^[11]提出一种基于模型剪枝的轻量化类级遗忘方法,通过统一模型剪枝(Federated unlearning with Uniform Model Pruning, FunUMP)策略移除与目标类数据相关的模型参数。然而,在边缘计算场景下,参与模型训练的节点通常是不同类型的边缘设备(如路由器、基站),节点软硬件环境等方面的差异导致其资源呈现出异构的特点^[12],如计算能力、存储容量和网络带宽等资源的异构性。因此, FunUMP的统一剪枝比分配策略面临效率瓶颈:高算力节点因过度剪枝而导致浪费资源,低算力节点因剪枝不足而造成训练时间增加,最终导致系统整体训练效率下降^[13]。

为解决上述问题,本文提出了一种基于自适应模型剪枝的联邦遗忘学习框架(Federated unlearning with Adaptive Model Pruning, FunAMP)。具体而言, FunAMP根据边缘节点的资源自适应分配合适的剪枝比,如为性能强的节点分配更小的剪枝比,为性能弱的节点分配更大的剪枝比,从而降低节点之间的等待时间,提高系统的资源利用率。此外,本文确立了一种衡量模型参数与目标类数据的指标,从而去除与目标类数据相关的模型参数。本文的贡献可以总结如下:

(1)提出了一种基于自适应模型剪枝的联邦遗忘学习框架(FunAMP),考虑边缘节点资源和模型性能约束,构建剪枝比决策问题,以最小化模型训练的完成时间。

(2)设计了一种基于贪心策略的剪枝比决策算法,根据节点的资源为其自适应分配合适的剪枝比,从而降低节点之间的等待时间,提高系统训练效率;确立了一种衡量模型参数与目标类数据的指标,通过去除与目标类数据相关的模型参数实现类级遗忘。

(3)从理论上分析了提出框架的性能,给出了算法的近似比。在多个数据集上对比了FunAMP与基线方法的性能,实验结果表明在达到相同准确率的情况下FunAMP框架最高可实现11.8倍的加速比。

2 系统模型与问题定义

2.1 系统模型

本文考虑一个包含 N 个边缘节点和一个中央服务器的联邦学习系统。每个节点 $i \in [N]$ (其中 $[N] = \{1, 2, \dots, N\}$ 代表节点集合)维护一个本地模型 w_i ,

并在其本地数据集 D_i 上优化损失函数 F_i 。具体而言,节点 i 的本地损失函数一般定义为^[14]

$$F_i(w_i) = \frac{1}{d_i} \sum_{x_i \in D_i} f_i(w_i; x_i) \quad (1)$$

其中 d_i 表示节点 i 的本地数据集 D_i 中包含的样本数量, x_i 表示 D_i 中的一个样本, $f_i(w_i; x_i)$ 表示基于样本 x_i 计算的损失函数。

服务器端则维护一个全局模型 w ,并通过聚合各节点的本地模型对其进行更新,以最小化全局损失函数 F 。全局损失函数通常被定义为各节点本地损失函数的加权和^[14]

$$F(w) = \sum_{i=1}^N \frac{d_i}{d} F_i(w) \quad (2)$$

其中 $d = \sum_{i=1}^N d_i$ 代表所有节点的样本总量。联邦学习的核心目标是通过分布式优化获得最优模型 w^* ,从而使全局损失函数最小,即

$$w^* = \arg \min_w F(w) \quad (3)$$

2.2 FunAMP框架

为应对由边缘节点资源异构导致的系统训练效率下降问题,本文提出了一种基于自适应模型剪枝的联邦遗忘学习框架(FunAMP)。当遗忘请求被提出时,服务器协调所有边缘节点通过以下3个步骤实现目标类的遗忘,具体流程如算法1所示。

(1)首先,服务器收集每个边缘节点 i 的计算资源 C_i 和通信带宽 B_i ,并根据 C_i 和 B_i 为节点 i 分配合适的剪枝比,以降低节点之间的等待时间,如算法1服务器侧的第(4)行所示。例如,节点1的性能较差,服务器为其分配了更大的剪枝比(0.7),剪枝后模型保留的参数更少(30%),可以显著降低模型训练和参数传递所需要的时间;对于性能较强的节点 N ,服务器分配了更小的剪枝比(0.2),更大程度地保证了模型的完整性,模型的性能也因此得到了保证。当确定了所有节点的剪枝比后,服务器将全局模型和决策的剪枝比下发到各个边缘节点。

(2)根据算法1边缘节点侧的第(3)~(4)行,在第 $e \in [E]$ 个全局训练轮次,当收到服务器下发的全局模型 w^e 和剪枝比 α_i^e 后,节点 i 根据剪枝比 α_i^e 对全局模型 w^e 进行剪枝。本文确立了基于词频-逆文频^[15](Term Frequency-Inverse Document Frequency, TF-IDF)的指标来衡量模型参数与目标类数据之间的相关性。具体而言,当参数对目标类的贡献较大(高词频)且对其他类的贡献较为均匀(高逆文频)时,本文认为该参数与目标类数据的相关性较高。以词频-逆文频指标为依据,逐步去除与目标类相

算法1 FumAMP的算法流程

输入：损失函数阈值 ε ，待遗忘的全局模型 $\mathbf{w}$ ，待遗忘数据的类别 l ，本地更新次数 τ
 输出：全局模型 $\mathbf{w}^E$

服务器：

- (1) 初始化全局模型 $\mathbf{w}^0 = \mathbf{w}$ ， $e = 0$
- (2) 获取每个节点 $i \in [N]$ 的计算能力 C_i 和通信带宽 B_i
- (3) While $F(\mathbf{w}^e) > \varepsilon$ do:
- (4) 调用算法2根据节点的资源为其分配合适的剪枝比
- (5) 将全局模型 $\mathbf{w}^e$ 和剪枝比 α_i^e 发送到对应的节点
- (6) 收集所有节点的本地模型并根据公式(5)更新全局模型
- (7) 调整更新轮次以开启下一轮训练 $e = e + 1$
- (8) End While
- (9) 向所有节点发送“停止”指令，令 $\mathbf{w}^E = \mathbf{w}^e$ 并输出边缘节点 i :
- (1) 将自身的计算能力 C_i 和通信带宽 B_i 上传到服务器
- (2) While 没有收到服务器的“停止”指令 do:
- (3) 从服务器接收全局模型 $\mathbf{w}^e$ 和剪枝比 α_i^e
- (4) 调用算法3根据剪枝比 α_i^e 对全局模型进行剪枝，从而剥离目标类 l 的贡献
- (5) 将第 e 轮初始的本地模型 $\mathbf{w}_i^{e,0}$ 指定为剪枝后的模型 $\tilde{\mathbf{w}}^e$
- (6) For $j = 1$ to τ
- (7) 根据公式(4)利用除目标类 l 之外的数据更新本地模型
- (8) End For
- (9) 将更新后的本地模型 $\mathbf{w}_i^{e,\tau}$ 上传到服务器
- (10) End While

关的模型参数，直到满足剪枝比 α_i^e 的要求。随后，如算法1边缘节点侧的第(6)~(8)行所示，剪枝后的模型 $\tilde{\mathbf{w}}^e$ 作为第 e 个轮次初始的本地模型 $\mathbf{w}_i^{e,0}$ ，按照随机梯度下降算法^[15](Stochastic Gradient Descent, SGD)在除目标类之外的数据上进行本地更新。在第 e 个全局轮次的第 j 次本地更新中，本地模型 $\mathbf{w}_i^{e,j}$ 的更新规则为

$$\mathbf{w}_i^{e,j} = \mathbf{w}_i^{e,j-1} - \eta \cdot \nabla F_{i,-l}(\mathbf{w}_i^{e,j-1}) \quad (4)$$

其中 η 代表模型更新时的学习率， $\nabla F_{i,-l}(\mathbf{w}_i^{e,j-1})$ 表示损失函数在目标类 l 之外的剩余数据上的梯度。 τ 次本地更新后，边缘节点 i 将更新后的本地模型 $\mathbf{w}_i^{e,\tau}$ 上传到服务器。

(3)当收集到所有边缘节点的本地模型后，服务器启动全局聚合，按照联邦平均算法^[2](Federated Averaging, FedAvg)更新全局模型

$$\mathbf{w}^{e+1} = \sum_{i=1}^N \frac{d_i}{d} \mathbf{w}_i^{e,\tau} \quad (5)$$

随后，服务器将更新后的全局模型下发到所有的边缘节点，以开启下一轮的更新。

上述3个步骤迭代执行直到全局模型的损失函数低于一个足够小的阈值 ε ，服务器向所有节点发送“停止”指令，待训练停止后将最后一轮的全局模型 $\mathbf{w}^E = \mathbf{w}^e$ 输出。

2.3 问题定义

考虑到边缘节点的资源异构性，令 C_i 表示节点 i 拥有的计算资源。同时，假设完整模型完成一次本地更新所需要的计算量为 s ，则节点 i 在第 e 轮全局更新时候需要的计算时间为^[13]

$$t_{i,\text{cmp}}^e = \frac{\tau \cdot (1 - \alpha_i^e) \cdot s}{C_i} \quad (6)$$

其中 α_i^e 代表节点 i 第 e 轮全局更新时的剪枝比。根据式(6)，模型更新时的计算时间与剪枝比密切相关：当剪枝比较大时，更多的模型参数被丢弃，完成模型更新需要的计算量更小，所以计算时间也随之变小；反之，当剪枝比减小时，计算时间随之增加。此外，除计算时间外，边缘节点完成一轮全局更新的时间还包括将本地模型上传到服务器所花费的通信时间，可以表示为

$$t_{i,\text{com}}^e = \frac{(1 - \alpha_i^e) \cdot |\mathbf{w}_i^{e,\tau}|}{B_i} \quad (7)$$

其中 $|\mathbf{w}_i^{e,\tau}|$ 代表模型参数的维度。根据式(6)和式(7)，节点 i 完成第 e 轮全局更新需要的总时间为

$$T_i^e = t_{i,\text{cmp}}^e + t_{i,\text{com}}^e \quad (8)$$

由于服务器需要等待所有边缘节点的本地模型都到达后才可以进行全局聚合，故第 e 轮全局更新实际需要的时间为所有节点中最大的更新时间，即 $T^e = \max_i T_i^e$ 。

综上所述，考虑边缘节点资源异构的自适应模型剪枝问题P1可以表示为

$$\text{P1: } \min_{\alpha_i^e} \sum_{e=1}^E T^e \quad (9)$$

$$F(\mathbf{w}^E) \leq \varepsilon \quad (9a)$$

$$\alpha_i^e \in (0, 1), \forall e \in [E], \forall i \in [N] \quad (9b)$$

其中 E 代表总的全局训练轮数。根据式(9)，该问题的优化目标为最小化模型的训练时间，以减轻边缘节点资源异构对模型训练效率造成的负面影响。为了保障模型的性能，约束式(9a)对 E 轮训练后全局模型的损失函数做出限制，保证其值小于一个接近0的常数 ε 。约束式(9b)限制了剪枝比的范围在区间(0,1)内，避免剪枝比为0时无法遗忘目标数据和剪枝比为1时模型失效的问题。

3 算法描述

3.1 基于贪心策略的剪枝比决策

为解决节点资源异构导致的训练效率下降问题,本文提出基于自适应模型剪枝的联邦遗忘学习框架。然而该问题的求解需要遍历 $O(\mathcal{R}^N)$ 的解空间,这在实际中并不可行。因此,本文将问题的目标转换为最小化所有节点更新时间的最大差距,即P2: $\min_{\alpha_i^e} \sum_{e=1}^E (\max_i T_i^e - \min_i T_i^e)$ 。针对新问题P2,本文提出了一种基于贪心策略的剪枝比决策算法,具体流程如算法2所示。

首先,服务器将连续剪枝空间 $(0,1)$ 按预设剪枝粒度 θ 离散化为集合 $\Phi_\theta = \{\alpha_z = z \cdot \theta | z = 1, 2, \dots, k\}$,其中离散点数量 k 由剪枝粒度确定: $k = \lceil (1 - \theta)/\theta \rceil$ 。接着,对于每个节点 i ,计算其在各离散剪枝比 α_z 下的更新时间 $T_{i,z}^e$,主要包括计算时间 $\tau \cdot (1 - \alpha_z) \cdot s/C_i$ 和通信时间 $(1 - \alpha_z) \cdot |w|/B_i$ 。随后采用二分搜索方法找到合适的参考更新时间(算法2的第(3)~(8)行):初始化全局搜索时间的上界 T_{high}^e 和下界 T_{low}^e 分别为所有节点中最大和最小的更新时间;计算 T_{high}^e 和 T_{low}^e 的中间值 T_{mid}^e ;对于每个节点 i ,寻找使 $T_{i,z_i}^e \geq T_{\text{mid}}^e$ 的最大的 z_i ;若所有节点均能找到对应的 z_i ,则将新的搜索时间上界 T_{high}^e 更新为 T_{mid}^e ,否则将搜索时间下界 T_{low}^e 更新为 T_{mid}^e 。将找到的可行时间 T_{high}^e 记为 T^* ,然后从 Φ_θ 中选择满足 $T_{i,z}^e \geq T^*$ 的最大的 z ,得到对应节点的剪枝比 $z \cdot \theta$ 并返回。

算法2将连续剪枝空间 $(0,1)$ 离散化为剪枝比集合,并利用二分搜索方法搜索合适的更新时间,可

以将时间复杂度控制在 $O(N \cdot k \cdot \log_2 k)$,并可通过增加剪枝粒度 θ 进一步降低算法的时间开销。

3.2 基于词频-逆文频的自适应模型剪枝

本节提出基于词频-逆文频的自适应模型剪枝算法,具体流程总结于算法3中。假设待剪枝的模型 w^e 共有 M 层,对于每层模型参数计算其与目标类 l 的词频-逆文频分数,具体步骤如下。

(1)计算词频(Term Frequency, TF)分数:令 $A_v(\xi)$ 表示输入样本为 ξ 时模型参数 v 的激活值, D^l 表示类别为 l 的数据,词频分数的计算方式为

$$\text{TF}(v, l) = \frac{\sum_{\xi \in D^l} \|A_v(\xi)\|}{|D^l|} \quad (10)$$

(2)计算逆文频(Inverse Document Frequency, IDF)分数:假设数据集中样本的总类别个数为 L , γ_v 代表模型参数 v 对每个类别的词频分数的平均值,逆文频的计算方式为

$$\text{IDF}(v) = \log_2 \left(\frac{L + 1}{\sum_{l'=1}^L \mathbb{I}[\text{TF}(v, l') > \gamma_v] + 1} \right) \quad (11)$$

其中 $\mathbb{I}$ 表示指示函数,当条件满足时为1,否则为0。

(3)计算词频-逆文频(Term Frequency-Inverse Document Frequency, TF-IDF)分数:基于TF分数和IDF分数,词频-逆文频分数的计算方式为

$$\text{TF-IDF}(v, l) = \text{TF}(v, l) \cdot \text{IDF}(v) \quad (12)$$

根据式(10)–式(12),词频分数衡量了模型对目标类 l 的局部贡献,逆文频分数衡量了参数对每个类别贡献的专一性。结合词频分数和逆文频分数,TF-IDF分数可以很好地表示模型参数与目标类数据的相关性。

完成TF-IDF分数的计算后,算法初始化累计剪枝比例 $r = 0$,并进入迭代剪枝阶段(算法3的第(5)~(8)行):在每一轮循环中,从剩余参数中选择当前TF-IDF分数最高的参数进行移除,同时更新累计剪枝比例 r ,直到 r 的值超过 α_i^e ,确保剪枝比例严格匹配预设目标 α_i^e 。最后,算法返回剪枝后的模型 $\tilde{w}^e$,该模型可以有效去除目标类的贡献,同时最大限度保留对其他类别的推理能力。

3.3 近似性能分析

在分析算法2得出的解与最优解之间的差距之前,先给出下面的引理。

引理1 对于任意节点 i 和 Φ_θ 中的剪枝比 α_z ,相邻时间差满足

算法2 基于贪心策略的剪枝比决策算法

输入: 剪枝比调整粒度 $\theta \in (0, 1)$, 节点计算能力 C_i , 通信带宽 B_i

输出: 各节点每轮剪枝比 $\alpha_i^e \in (0, 1)$

- (1) 根据 θ 将剪枝区间离散化为 $\Phi_\theta = \{\alpha_z = z \cdot \theta | z = 1, 2, \dots, k\}$, 其中 $k = \lceil (1 - \theta)/\theta \rceil$
- (2) 对于每个节点 i , 根据式(6)–式(8)计算其在剪枝比 α_z 下的时间 $T_{i,z}^e$
- (3) 初始化全局时间下界 T_{low}^e 和上界 T_{high}^e 分别为
 $T_{\text{low}}^e = \min_i T_{i,1}^e$, $T_{\text{high}}^e = \max_i T_{i,z}^e$
- (4) While $T_{\text{high}}^e > T_{\text{low}}^e$ do:
- (5) 令 $T_{\text{mid}}^e = (T_{\text{high}}^e + T_{\text{low}}^e)/2$
- (6) 对于每个节点 i , 选择最大的 z_i 使得 $T_{i,z_i}^e \geq T_{\text{mid}}^e$
- (7) 若存在可行解(所有节点均能找到对应的 z_i), 则更新
 $T_{\text{high}}^e = T_{\text{mid}}^e$, 否则更新 $T_{\text{low}}^e = T_{\text{mid}}^e$
- (8) End While
- (9) 将得到的可行 T_{high}^e 记为 T^*
- (10) 对于每个节点 i , 选择 $z_i = \arg \max_z \{T_{i,z}^e \geq T^*\}$
- (11) 返回所有节点的剪枝比 $\{\alpha_{z1}, \alpha_{z2}, \dots, \alpha_{zN}\}$

算法3 基于词频-逆文频的自适应模型剪枝算法

输入：剪枝比 α_i^e ，待剪枝模型参数 $\mathbf{w}^e$ ，目标类 l

输出：剪枝后的模型 $\tilde{\mathbf{w}}^e$

- (1) For $m = 1$ to M
- (2) 根据式(10)–式(12)计算第 m 层模型参数与目标类 l 的TF-IDF分数
- (3) End For
- (4) 初始化累计剪枝比例 $r = 0$
- (5) While $r < \alpha_i^e$ do:
- (6) 逐步去除剩余参数中与目标类 l 最相关的模型参数
- (7) 更新累计剪枝比例 r
- (8) End While
- (9) 返回剪枝后的模型 $\tilde{\mathbf{w}}^e$

$$T_{i,z}^e - T_{i,z+1}^e \leq \delta_i \quad (13)$$

证明 根据式(6)–式(8)中 T_i^e 的定义可以得出

$$\begin{aligned} T_{i,z}^e - T_{i,z+1}^e &= \left(\frac{\tau \cdot (1 - \alpha_z) \cdot s}{C_i} + \frac{(1 - \alpha_z) \cdot |\mathbf{w}|}{B_i} \right) \\ &\quad - \left(\frac{\tau \cdot (1 - \alpha_{z+1}) \cdot s}{C_i} + \frac{(1 - \alpha_{z+1}) \cdot |\mathbf{w}|}{B_i} \right) \\ &= \left(\frac{\tau \cdot (\alpha_{z+1} - \alpha_z) \cdot s}{C_i} + \frac{(\alpha_{z+1} - \alpha_z) \cdot |\mathbf{w}|}{B_i} \right) \\ &= \theta \cdot \left(\frac{\tau \cdot s}{C_i} + \frac{|\mathbf{w}|}{B_i} \right) \end{aligned} \quad (14)$$

对于节点 i ，式(14)中的参数均与 z 无关，令 $\delta_i = \theta \cdot (\tau \cdot s / C_i + |\mathbf{w}| / B_i)$ ，可得到引理1。

证毕

定理1 令 Δ_{opt} 和 Δ_{algo} 分别代表最优解和算法解下节点更新时间的最大差距，算法2的近似比为

$$\frac{\Delta_{\text{algo}}}{\Delta_{\text{opt}}} \leq 1 + \frac{2 \cdot \delta_{\max}}{\Delta_{\text{opt}}} \quad (15)$$

其中 $\delta_{\max} = \max_i \delta_i$ 代表所有节点中最大的相邻时间差。

证明 设最优解中节点 i 的时间为 T_i^* ，对应剪枝比为 α_i^* 。经过离散化，存在 z'_i ，使得

$$\alpha_{z'_i}^* \leq \alpha_i^* \leq \alpha_{z'_i+1}^* \Rightarrow T_{i,z'_i}^e \geq T_i^* \geq T_{i,z'_i+1}^e \quad (16)$$

算法2选择的 z_i 满足 $T_{i,z_i}^e \geq T^*$ ，且有 $|T^* - T_i^*| \leq \delta_i$ ，根据引理1可得

$$T_i^* - \delta_i \leq T^* \leq T_{i,z_i}^e \leq T_i^* + \delta_i \quad (17)$$

进一步地，将所有节点更新时间的最大差距分解可得

$$\begin{aligned} \Delta_{\text{algo}} &= \max_i T_{i,z_i}^e - \min_i T_{i,z_i}^e \\ &\leq \max_i (T_i^* + \delta_i) - \min_i (T_i^* - \delta_i) \\ &\leq \max_i T_i^* - \min_i T_i^* + 2 \cdot \delta_{\max} = \Delta_{\text{opt}} + 2 \cdot \delta_{\max} \end{aligned} \quad (18)$$

同时将式(18)的两边除以 Δ_{opt} ，可得到定理1中的结果。

证毕

4 实验

4.1 实验设置

4.1.1 环境设置

为验证FunAMP框架及相关算法的性能，本文使用Pytorch深度学习库模拟了一个典型的联邦学习环境，包含一个服务器和10个边缘节点。环境部署在一台AMAX深度学习工作站上，该工作站配备一块Intel Skylake Xeon CPU以及一张NVIDIA RTX A6000 GPU，显存大小为48 GB。为体现边缘节点的资源异构性，本节统计了多种商业设备(包括NVIDIA Jetson TX2, XAVIER NX, 以及AGX XAVIER)的性能，并将每个边缘节点的资源设置为3种商业设备中的一种。同时，为了体现不同异构程度对FunAMP的影响，本节通过调整3种NVIDIA设备的性能模式组合得到3种异构设置：低、中、高，其中每种设置下设备的最大性能差距分别在5倍、10倍和20倍。除非特别指定，实验均在中等异构程度下进行。

4.1.2 数据集和模型

本文在FMNIST^[16]和CIFAR-100^[17]2个数据集上对框架的性能进行测试。具体而言，FMNIST是一个10分类的灰度图像数据集，包含60 000个训练样本和10 000个测试样本。由于FMNIST数据集分类难度较低，本节采用LeNet和AlexNet对其进行处理。CIFAR-100是一个细粒度的彩色图像分类数据集，共包含50 000个训练样本和10 000个测试样本，样本类别数目为100。考虑到CIFAR-100数据集细粒度的类别数目和复杂的类间特征，本节采用VGG11和VGG16来处理该任务。在实验中，2个数据集待遗忘的目标类分别被设置为类别9和类别99^[11]。此外，为验证FunAMP在不同数据分布下的鲁棒性，本节通过调整训练样本的数量和标签引入3种数据分布。其中，分布1设置下节点训练样本的数量和标签服从相同分布。剩余2种分布则参考Pat^[18]数据划分方式，每个节点的训练样本仅拥有50%(分布2)和20%(分布3)的标签，同时节点样本数量的最大差距分别为2倍(分布2)、5倍(分布3)。根据设置，分布3比分布2的非独立同分布程度更高。除非特别指定，实验的数据分布设置均采用分布1。

4.1.3 对比方法

为了验证FunAMP的优势，本文采用以下2种机制作为对比方法。(1)FunUMP，按照文献[11]的思路，采用统一全局剪枝的方法为所有节点分配

相同的剪枝比,并通过微调恢复模型的性能;
(2)ReTrain,利用除目标类之外的剩余数据重新训练模型。

4.2 实验结果

4.2.1 剪枝粒度的影响

为分析给定训练时间下不同剪枝粒度的影响,图1展示了 θ 从0.00增加至0.25时FunAMP的准确率。对于4个模型,训练时间分别被指定为1 000 s (LeNet)、2 500 s (AlexNet)、6 000 s (VGG11)和8 000 s (VGG16)。由图可知,对于2个数据集,当扩大模型规模时,FunAMP的准确率均有提升。例如,当剪枝粒度为0.03时,LeNet在FMNIST上的准确率为76.26%,而AlexNet取得了83.12%的准确率。此外,不同剪枝粒度对模型的性能有显著影响。具体而言,当剪枝粒度为0.00时,模型不剪枝,节点的资源异构性严重影响效率,导致模型准确率下降。当剪枝粒度从0.01增加至0.25后,模型的准确率也呈下降趋势,这是由于剪枝粒度的增加导致选择的剪枝比无法精准匹配节点的性能。此外,由于参数冗余,相对于简单的模型(LeNet和VGG11),复杂模型(AlexNet和VGG16)对剪枝粒度的增加有更高的容忍度,准确率下降趋势相对平缓。对于4个模型,当剪枝粒度为0.01时,FunAMP取得最好的性能,4个模型的准确率分别为76.48%(LeNet),

83.60%(AlexNet)、46.93%(VGG11), 55.69%(VGG16)。因此,在后续的实验中FunAMP的剪枝粒度被设置为0.01。

4.2.2 给定训练时间下的准确率对比

图2展示了在给定训练时间下3种方法的准确率。由图可知,ReTrain方法总是取得最低的准确率,原因是ReTrain利用除目标类外的剩余数据重新训练完整的模型,容易因节点资源异构导致训练效率下降,需要更长的训练时间模型才能达到收敛。FunAMP采用统一全局剪枝的方法为所有的节点分配相同的剪枝比,可以在一定程度上缓解节点资源异构挑战的影响,因而在给定的训练时间内相对于ReTrain方法取得了更高的准确率。相对而言,FunAMP框架根据节点的资源为其分配合适的剪枝比,可以有效降低节点之间的等待时间,提高系统训练效率,在3种方法中取得了最高的准确率。总的来说,在4个模型(LeNet, AlexNet, VGG11, VGG16)上, FunAMP相对于FunUMP方法将准确率分别提升了5.93, 4.44, 3.43, 1.67个百分点,充分表明了自适应模型剪枝策略的优势。

4.2.3 遗忘效果对比

为进一步说明自适应模型剪枝策略的优势,本节对比了给定训练时间内不同方法的准确率和遗忘效果(在目标类上的准确率),训练时间的设置与图2




图1 不同剪枝粒度的对比




图2 给定时间内的准确率对比

一致，结果如表1所示。由表可知，在3种方法中，FunAMP总是取得最高的准确率。例如，对于LeNet模型，FunAMP的准确率为76.48%，而FunUMP和ReTrain的准确率分别为70.55%，60.48%，说明FunAMP方法可以有效提高模型训练效率，因而在给定训练时间内取得了更高的准确率。在遗忘效果方面，ReTrain从训练数据中剔除了目标类的数据，所以在目标数据上的准确率为0.00%。而2种剪枝方案(FunAMP和FunUMP)通过去除与目标类数据相关的模型参数，也可以剥离目标类数据的贡献。综上所述，在给定训练时间内，FunAMP可以在保证完全遗忘目标类数据的情况下提高模型的准确率，在3种方法中具有明显的优势。

4.2.4 不同异构程度的影响

图3展示了在3种异构程度(低、中、高)下，3种方法达到预设准确率所需要的训练时间。预设准确率的设置参考图2中ReTrain在给定时间内取得

的最大准确率，在4个模型上分别设置为60.00%(LeNet)，70.00%(AlexNet)，40.00%(VGG11)，45.00%(VGG16)。由图可知，随着异构程度的升高，所有方法均需要更长的训练时间才能达到预设的准确率，原因在于高异构程度下节点的性能差距扩大，模型训练效率进一步降低。在3种方法中，FunAMP总能在更短的时间内达到预设的准确率。具体而言，在取得预设准确率的情况下FunAMP相对于其他2种方法取得的最大加速比分别为11.0(LeNet)，11.8(AlexNet)，5.62(VGG11)，4.70(VGG16)。

4.2.5 不同数据分布的影响

为说明FunAMP在不同数据分布下的鲁棒性，本节对比了给定训练时间内3种方法在不同数据分布(分布1,2,3)下的准确率，结果如图4所示。其中4种模型的训练时间分别被指定为1 000s(LeNet)，2 500 s(AlexNet)，6 000 s(VGG11)和8 000 s

表 1 给定训练时间内不同方法的准确率和遗忘效果对比(%)

	FMNIST				CIFAR-100			
	LeNet		AlexNet		VGG11		VGG16	
	准确率	遗忘效果	准确率	遗忘效果	准确率	遗忘效果	准确率	遗忘效果
FunAMP	76.48	00.00	83.60	00.00	46.93	00.00	55.69	00.00
FunUMP	70.55	00.00	79.16	00.00	43.50	00.00	54.02	00.00
ReTrain	60.48	00.00	72.68	00.00	39.82	00.00	44.95	00.00

注：粗体表示所有方案中准确率的最高值




图 3 不同异构程度下达到预设准确率的完成时间对比




图 4 不同数据分布下给定训练时间的准确率对比

(VGG16)。由图可知,随着数据非独立同分布程度的升高,所有方法在给定训练时间内能达到的准确率均显著下降,原因在于各个节点训练样本的数量和标签分布差异增大,导致聚合后的全局模型偏离了最优方向。在3种方法中, FunAMP总能在给定的训练时间内取得更高的准确率。总的来说,在4个模型上, FunAMP相对于FunUMP方法最高可 将准确率提高6.87, 4.44, 4.17, 2.25个百分点。

上述实验结果表明,在不同的异构程度和数据分布下,本文提出的FunAMP框架比其他对比方法有更好的训练性能,能更好地应对因边缘节点资源异构导致的训练效率下降问题。

5 结束语

为了应对因边缘节点资源异构导致的训练效率下降问题,本文提出了一种基于自适应模型剪枝的联邦遗忘学习框架(FunAMP)。首先,对模型训练时间、节点资源与模型剪枝比进行建模,建立剪枝比决策问题。接着,设计了一种基于贪心策略的剪枝比决策算法,根据节点异构的资源为其分配合适的剪枝比,以最小化模型训练的完成时间。然后,从理论上分析剪枝比决策算法的近似性能,并给出相关证明。最后,确立了一种基于词频-逆文频的剪枝算法,将与目标类数据相关的模型参数去除,以剥离目标类数据的贡献。实验结果表明, FunAMP框架及相关算法可以在保证遗忘效果的前提下显著提高模型训练效率。

参 考 文 献

- [1] SHI Weisong, CAO Jie, ZHANG Quan, *et al.* Edge computing: Vision and challenges[J]. *IEEE Internet of Things Journal*, 2016, 3(5): 637–646. doi: 10.1109/JIOT.2016.2579198.
- [2] MCMAHAN B, MOORE E, RAMAGE D, *et al.* Communication-efficient learning of deep networks from decentralized data[C]. The 20th International Conference on Artificial Intelligence and Statistics, Fort Lauderdale, USA, 2017: 1273–1282.
- [3] 管桂林, 陶政坪, 支婷, 等. 面向医疗场景的去中心化联邦学习隐私保护方法[J]. 计算机应用, 2024, 44(S2): 112–117. doi: 10.11772/j.issn.1001-9081.2024030347.
GUAN Guilin, TAO Zhengping, ZHI Ting, *et al.* Decentralized federated learning privacy protection method for medical scenarios[J]. *Journal of Computer Applications*, 2024, 44(S2): 112–117. doi: 10.11772/j.issn.1001-9081.2024030347.
- [4] 智慧, 段苗苗, 杨利霞, 等. 一种基于区块链和联邦学习融合的交通流预测方法[J]. 电子与信息学报, 2024, 46(9): 3777–3787. doi: 10.11999/JEIT240030.
- [5] ZHI Hui, DUAN Miaomiao, YANG Lixia, *et al.* A traffic flow prediction method based on the fusion of blockchain and federated learning[J]. *Journal of Electronics & Information Technology*, 2024, 46(9): 3777–3787. doi: 10.11999/JEIT240030.
- [6] 郑润达, 张维, 张永杰, 等. 金融领域中的联邦学习研究[J]. 数智技术研究与应用, 2025, 1(1): 1–17. doi: 10.26917/j.cnki.issn.2097-597X.2025.01.001.
- [7] ZHENG Runda, ZHANG Wei, ZHANG Yongjie, *et al.* Research on federated learning in the field of finance[J]. *SmartTech Innovations*, 2025, 1(1): 1–17. doi: 10.26917/j.cnki.issn.2097-597X.2025.01.001.
- [8] 肖雄, 唐卓, 肖斌, 等. 联邦学习的隐私保护与安全防御研究综述[J]. 计算机学报, 2023, 46(5): 1019–1044. doi: 10.11897/SP.J.1016.2023.01019.
- [9] XIAO Xiong, TANG Zhuo, XIAO Bin, *et al.* A survey on privacy and security issues in federated learning[J]. *Chinese Journal of Computers*, 2023, 46(5): 1019–1044. doi: 10.11897/SP.J.1016.2023.01019.
- [10] LIU Ziyao, JIANG Yu, SHEN Jiyuan, *et al.* A survey on federated unlearning: Challenges, methods, and future directions[J]. *ACM Computing Surveys*, 2025, 57(1): 2. doi: 10.1145/3679014.
- [11] WU Leijie, GUO Song, WANG Junxiao, *et al.* Federated unlearning: Guarantee the right of clients to forget[J]. *IEEE Network*, 2022, 36(5): 129–135. doi: 10.1109/MNET.001.2200198.
- [12] WANG Zichen, GAO Xiangshan, WANG Cong, *et al.* Efficient vertical federated unlearning via fast retraining[J]. *ACM Transactions on Internet Technology*, 2024, 24(2): 11. doi: 10.1145/3657290.
- [13] SYROS G, YAR G, BOBOILA S, *et al.* Backdoor attacks in peer-to-peer federated learning[J]. *ACM Transactions on Privacy and Security*, 2025, 28(1): 8. doi: 10.1145/3691633.
- [14] WANG Junxiao, GUO Song, XIE Xin, *et al.* Federated unlearning via class-discriminative pruning[C]. The ACM Web Conference, Lyon, France, 2022: 622–632. doi: 10.1145/3485447.3512222.
- [15] WANG Lun, XU Yang, XU Hongli, *et al.* BOSE: Block-wise federated learning in heterogeneous edge computing[J]. *IEEE/ACM Transactions on Networking*, 2024, 32(2): 1362–1377. doi: 10.1109/TNET.2023.3316421.
- [16] JIANG Zhida, XU Yang, XU hongli, *et al.* Computation and communication efficient federated learning with adaptive model pruning[J]. *IEEE Transactions on Mobile Computing*, 2024, 23(3): 2003–2021. doi: 10.1109/TMC.2023.3247798.
- [17] MA Zhenguo, XU Yang, XU Hongli, *et al.* Adaptive batch

- size for federated learning in resource-constrained edge computing[J]. *IEEE Transactions on Mobile Computing*, 2023, 22(1): 37–53. doi: 10.1109/TMC.2021.3075291.
- [15] AIZAWA A. An information-theoretic perspective of tf-idf measures[J]. *Information Processing & Management*, 2003, 39(1): 45–65. doi: 10.1016/S0306-4573(02)00021-3.
- [16] XIAO Han, RASUL K, and VOLLGRAF R. Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms[J]. arXiv preprint arXiv: 1708.07747, 2017. doi: 10.48550/arXiv.1708.07747.
- [17] KRIZHEVSKY A, NAIR V, and HINTON G. The CIFAR-100 dataset[EB/OL]. <http://www.cs.toronto.edu/~kriz/cifar.html>, 2024.
- [18] PAN Zibin, WANG Zhichao, LI Chi, *et al.* Federated unlearning with gradient descent and conflict mitigation[C]. The 39th AAAI Conference on Artificial Intelligence, Philadelphia, USA, 2025: 19804–19812. doi: 10.1609/aaai.v39i19.34181.
- 马振国：男，副教授，研究方向为边缘计算、联邦学习等。
- 和孜轩：男，博士生，研究方向为边缘计算、视频分析、深度强化学习等。
- 孙彦景：男，教授，博士生导师，研究方向为无线通信、物联网、嵌入式系统等。
- 王博文：男，副教授，硕士生导师，研究方向为应急无线通信、工业物联网等。
- 刘建春：男，副研究员，硕士生导师，研究方向为联邦学习、联邦大模型等。
- 徐宏力：男，教授，博士生导师，研究方向为软件定义网络、物联网、边缘计算、联邦学习等。
- 责任编辑：廖海贝

Research on Federated Unlearning Approach Based on Adaptive Model Pruning

MA Zhenguo^{①②} HE Zixuan^③ SUN Yanjing^{①②} WANG Bowen^{③④}
LIU Jianchun^{⑤⑥} XU Hongli^{⑤⑥}

^①(School of Computer Science and Technology, China University of Mining and Technology, Xuzhou 221116, China)

^②(School of Artificial Intelligence, China University of Mining and Technology, Xuzhou 221116, China)

^③(School of Information and Control Engineering, China University of Mining and Technology, Xuzhou 221116, China)

^④(IoT Perception Mine Research Center, China University of Mining and Technology, Xuzhou 221116, China)

^⑤(School of Computer Science and Technology, University of Science and Technology of China, Hefei 230026, China)

^⑥(Suzhou Institute for Advanced Research, University of Science and Technology of China, Suzhou 215123, China)

Abstract:

Objective The rapid proliferation of Internet of Things (IoT) devices and the enforcement of data privacy regulations, including the General Data Protection Regulation (GDPR) and the Personal Information Protection Act, have positioned Federated Unlearning (FU) as a critical mechanism to safeguard the “right to be forgotten” in Edge Computing (EC). Existing class-level unlearning approaches often adopt uniform model pruning strategies. However, because edge nodes vary substantially in computational capacity, storage, and network bandwidth, these methods suffer from efficiency degradation, leading to imbalanced training delays and decreased resource utilization. This study proposes FU with Adaptive Model Pruning (FunAMP), a framework that minimizes training time while reliably eliminating the influence of target-class data. FunAMP dynamically assigns pruning ratios according to node resources and incorporates a parameter correlation metric to guide pruning decisions. In doing so, it addresses the challenge of resource heterogeneity while preserving compliance with privacy regulations.

Methods The proposed framework establishes a quantitative relationship among model training time, node resources, and pruning ratios, on the basis of which an optimization problem is formulated to minimize overall

training time. To address this problem, a greedy algorithm (Algorithm 2) is designed to adaptively assign appropriate pruning ratios to each node. The algorithm discretizes the pruning ratio space and applies a binary search strategy to balance computation and communication delays across nodes. Additionally, a Term Frequency-Inverse Document Frequency (TF-IDF)-based metric is introduced to evaluate the correlation between model parameters and the target-class data. For each parameter, the TF score reflects its activation contribution to the target class, whereas the IDF score measures its specificity across all classes. Parameters with high TF-IDF scores are iteratively pruned until the assigned pruning ratio is satisfied, thereby ensuring the effective removal of target-class data.

Results and Discussions Simulation results confirm the effectiveness of FunAMP in balancing training efficiency and unlearning performance under resource heterogeneity. The effect of pruning granularity on model accuracy (Fig. 1): fine granularity (e.g., 0.01) preserves model integrity, whereas coarse settings degrade accuracy due to excessive parameter removal. Under fixed training time, FunAMP consistently achieves higher accuracy than FunUMP and Retrain (Fig. 2), as adaptive pruning ratios reduce inter-node waiting delays. For instance, FunAMP attains 76.48% accuracy on LeNet and 83.60% on AlexNet with FMNIST, outperforming baseline methods by 5.91% and 4.44%, respectively. The TF-IDF-driven pruning mechanism fully removes contributions of target-class data, achieving 0.00% accuracy on the target data while maintaining competitive performance on the remaining data (Table 1). Robustness under varying heterogeneity levels is further verified (Fig. 3). Compared with baselines, FunAMP markedly reduces the training time required to reach predefined accuracy and delivers up to $11.8\times$ speedup across four models. These results demonstrate FunAMP's capability to harmonize resource utilization, preserve model performance, and ensure unlearning efficacy in heterogeneous edge environments.

Conclusions To mitigate training inefficiency caused by resource heterogeneity in FU, this study proposes FunAMP, a framework that integrates adaptive pruning with parameter relevance analysis. A system model is constructed to formalize the relationship among node resources, pruning ratios, and training time. A greedy algorithm dynamically assigns pruning ratios to edge nodes, thereby minimizing global training time while balancing computational and communication delays. Furthermore, a TF-IDF-driven metric quantifies the correlation between model parameters and target-class data, enabling the selective removal of critical parameters to erase target-class contributions. Theoretical analysis verifies the stability and reliability of the framework, while empirical results demonstrate that FunAMP achieves complete removal of target-class data and sustains competitive accuracy on the remaining classes. This work is limited to single-class unlearning, and extending the approach to scenarios requiring the simultaneous removal of multiple classes remains an important direction for future research.

Key words: Federated Unlearning (FU); Resource heterogeneity; Adaptive model pruning; Correlation metric; Performance analysis